

针对心肌细胞分割的 Segment Anything Model (SAM) 微调与优化: 2023-2025 年前沿研究综述与技术路径报告

1. 引言: 计算病理学中的基础模型范式转移

在过去的三年(2023-2025)中, 生物医学图像分析领域经历了一场深刻的范式转移。随着 Meta AI 发布 Segment Anything Model (SAM), 传统的基于全卷积网络(FCN)和 U-Net 架构的分割方法正逐渐被基于 Vision Transformer (ViT) 的基础模型(Foundation Models)所取代。这一转变不仅重新定义了图像分割的边界, 也为解决长期困扰细胞生物学——特别是心肌细胞(Cardiomyocytes, CMs)表型分析——的复杂分割难题提供了全新的契机。

心肌细胞, 特别是人类诱导多能干细胞分化来源的心肌细胞(hiPSC-CMs), 因其高度异质性的形态、复杂的肌节(Sarcomere)结构以及在体外培养中形成的致密组织层, 长期以来被视为细胞分割任务中的“高地”。传统的分割算法难以处理其模糊的边界和各向异性的生长模式, 导致高通量表型筛选和药物毒性测试的准确性受限。Allen Institute for Cell Science 和 Van Valen Lab 等先驱机构的研究表明, 精确的单细胞分割是将复杂的转录组学数据映射到空间结构的关键步骤¹。

本报告旨在系统性地梳理 2023 年至 2025 年间, 围绕 SAM 在细胞分割领域的微调与优化研究。我们将深入分析 NeurIPS、MICCAI、CVPR 等顶级会议及生物医学领域的最新文献, 重点剖析 CellSAM、Cellpose-SAM、MedSAM 等模型的架构演进, 并详细探讨 LoRA (Low-Rank Adaptation) 等参数高效微调技术在心肌细胞分割中的应用策略, 为构建下一代高精度心肌细胞分析流程提供详实的理论支持和技术路线图。

2. 心肌细胞分割的挑战与 Allen Institute 数据集的启示

在深入探讨模型架构之前, 必须深刻理解目标对象——心肌细胞——的生物学特性及其在成像数据中的表现。这一理解构成了后续所有微调策略的物理基础。

2.1 心肌细胞的形态学复杂性与分割难点

心肌细胞不同于血液细胞或淋巴细胞, 后者通常呈圆形或椭圆形, 具有清晰的凸包(Convex Hull)特征。成熟的心肌细胞呈现出显著的各向异性(Anisotropy), 通常发育为细长的杆状或多边形结构, 长宽比可达 7:1 甚至更高¹。在体外培养环境下, hiPSC-CMs 往往形成紧密连接的单层细胞片(Cell Sheet), 细胞与细胞之间的边界在明场(Brightfield)或相差显微镜下极其模糊, 仅通过细胞核(Nuclei)的位置难以推断细胞质(Cytoplasm)的范围。

Allen Institute 的研究指出, 心肌细胞的结构组织性(Structural Organization)是衡量其成熟度和健康状态的重要指标¹。这种组织性主要体现在肌节的排列上。然而, 传统的通用分割模型(如原始 SAM)是在自然图像(SA-1B 数据集)上训练的, 其主要关注的是物体边缘的梯度变化和色彩差

异, 对于这种内部纹理高度重复(周期性肌节)、外部边界模糊的生物对象, 极易产生两类错误:

1. 过度分割(**Over-segmentation**): 将一个细长的心肌细胞错误地切断为多个碎片, 这通常是因为模型将细胞内部的细胞器或肌节纹理误判为边缘。
2. 欠分割(**Under-segmentation**): 将相邻且纹理相似的多个心肌细胞融合为一个连通区域, 尤其是在细胞汇合度(Confluency)较高时。

2.2 Allen Institute 数据集的多模态特征

Allen Institute 发布的 hiPSC-CM 数据集为解决上述问题提供了宝贵的资源。该数据集的一个显著特征是“集成转录组学与结构组织”(Integrated Transcriptomics and Structural Organization)³。数据集不仅包含明场图像, 还通过基因编辑技术标记了关键结构蛋白, 如 α -actinin-2 (标记 Z-disc/肌节) 和细胞膜标记物。

这种多模态数据揭示了一个关键的微调思路: 单纯依赖单一模态(如明场或核染)进行心肌细胞分割是困难的, 必须利用肌节的结构信息作为辅助监督信号。SarcGraph 框架的提出正是基于这一逻辑, 它通过检测 Z-disc 来构建肌节网络, 进而反推细胞的结构完整性¹。因此, 在微调 SAM 时, 如果能够将 SarcGraph 提取的 Z-disc 密度图或方向场作为先验信息(Prior)注入模型, 或作为提示(Prompt)的一部分, 将极大地提升分割的生物学合理性。

3. 基础模型在细胞分割中的架构演进 (2023-2025)

针对细胞分割的特殊需求, 学术界在 2023-2025 年间对 SAM 进行了多种形式的改造。这些改造大致可分为两类: 一类是引入生物学先验的架构融合(如 CellSAM, Cellpose-SAM), 另一类是针对医学图像分布的参数适配(如 MedSAM, BioSAM)。

3.1 CellSAM: 检测驱动的通用分割模型

由 Van Valen Lab 开发的 **CellSAM** 代表了将 SAM 适配于高通量细胞生物学的早期成功尝试²。CellSAM 的核心设计哲学是“自动化提示工程”(Automated Prompt Engineering)。

由于 SAM 是一个提示驱动(Prompt-driven)的模型, 其零样本分割能力高度依赖于提示(如点击、边界框)的质量。在包含数千个细胞的显微图像中, 手动提供提示是不现实的。CellSAM 引入了一个名为 **CellFinder** 的轻量级对象检测器。CellFinder 类似 YOLO 或 RetinaNet, 被训练用于快速定位图像中的细胞并生成边界框(Bounding Boxes)。这些边界框随后被作为提示输入到 SAM 的图像编码器中, 从而生成高质量的实例掩码。

对于心肌细胞而言, CellSAM 的架构优势在于其解耦性: 用户可以单独训练一个针对细长心肌细胞优化的检测器(例如使用旋转边界框 Rotated Bounding Box 来适应细胞取向), 而保持 SAM 强大的分割头(Mask Decoder)不变。这避免了端到端重新训练整个大模型的昂贵成本, 同时利用了 SAM 在边缘细化方面的优势。

3.2 Cellpose-SAM: 流场与语义特征的深度融合

如果说 CellSAM 是“检测+分割”的串联, 那么 **Cellpose-SAM** 则是“流场+特征”的深度融合, 这

对于心肌细胞分割尤为重要⁶。

Cellpose 算法的核心在于预测细胞的拓扑流场 (Flow Fields)，即图像中每个像素指向其所属细胞中心的向量场。这种表示方法对于非凸形状 (Non-convex) 和紧密接触的物体具有天然的鲁棒性，因为它将分割问题转化为了基于梯度的动力学追踪问题。然而，原始 Cellpose 使用基于 ResNet 的 U-Net 骨干，其感受野 (Receptive Field) 有限，难以捕捉横跨数百像素的超长心肌细胞的全局上下文。

Cellpose-SAM 创新性地 将 SAM 的 Vision Transformer (ViT) 骨干网络引入 Cellpose 架构。ViT 通过自注意力机制 (Self-Attention) 提供了全局感受野，使得模型在处理长条形结构时，能够感知到细胞两端的关联性。2025 年的研究表明，Cellpose-SAM 在处理具有复杂形态的细胞时，展现出了“超人类”的泛化能力 (Superhuman Generalization)，能够跨越不同的成像模态和细胞类型，且在处理心肌细胞这种细长结构时，显著减少了断裂错误⁶。对于心肌细胞分割，Cellpose-SAM 的流场预测机制是目前处理细胞粘连 (Touching Cells) 最有效的手段之一。

3.3 MedSAM, BioSAM 与 MicroSAM: 领域适应与参数效率

与 CellSAM 和 Cellpose-SAM 侧重于架构改造不同，MedSAM¹⁰ 和 BioSAM 更多地侧重于数据层面的领域适应。

MedSAM 旨在成为医学图像领域的通用分割模型。它通过收集包含 CT、MRI、病理切片等多种模态的百万级医学图像数据集，对 SAM 进行了全量的微调或适配器微调。虽然 MedSAM 在宏观器官分割上表现出色，但在微观的细胞分割任务上，其性能往往不如专门设计的 CellSAM。这是因为 CT/MRI 的语义特征 (如器官形状、密度) 与显微镜下的细胞纹理 (如相位干涉、荧光强度) 存在本质差异。

MicroSAM (及类似的 μ SAM)¹¹ 则更进一步，专注于显微镜图像的领域适应。这类模型通常在特定的显微数据集 (如 TissueNet, LiveCell) 上进行微调，旨在解决 SAM 在低信噪比和特殊染色条件下的失效问题。对于心肌细胞分割，直接使用 MedSAM 可能效果欠佳，因为其预训练数据中缺乏足够的心肌细胞样本；而基于 MicroSAM 的思路，构建一个专注于肌节纹理和细胞骨架的专用模型，是更具潜力的方向。

表 1: 主流 SAM 改进模型在心肌细胞分割任务中的特性对比

模型名称	核心架构特征	提示机制 (Prompting)	对心肌细胞分割的优势	潜在局限性
CellSAM ²	ViT Encoder + CellFinder (Detector)	自动边界框 (Auto-Box)	流程自动化，适合高通量筛选；易于集成新的检测器。	若检测器无法识别不规则形状，分割将直接失败；对重叠细胞处理较弱。

Cellpose-SAM ⁶	ViT Backbone + Flow Field Decoder	无需显式提示 (Auto) 或 ROI	最佳的拓扑保持能力;流场机制极适合分离粘连的细长细胞。	计算开销大,推理速度较慢;对训练数据的标注质量要求极高。
MedSAM ¹⁰	ViT-B + Adapter	边界框 (Box)	泛化能力强,已有医学预训练权重。	分辨率可能不足以捕捉肌节细节;缺乏针对细胞形态的归纳偏置。
MicroSAM / BioSAM ¹¹	ViT + Domain Specific FT	多样化	针对显微成像优化,适应不同染色。	预训练数据可能未覆盖 hiPSC-CM 的特殊形态。
ScribblePrompt-SAM ¹²	ViT + Interactive Head	涂鸦 (Scribbles) / 骨架	极高的人机交互效率;适合修正细长细胞的断裂。	主要是交互式工具,全自动流水线集成难度较大。

4. 参数高效微调 (PEFT) 技术: SAM 适配心肌细胞的核心引擎

尽管 SAM 具有强大的能力,但其巨大的参数量 (ViT-H 约为 636M 参数)使得在普通的实验室硬件上进行全量微调 (Full Fine-tuning) 变得极其昂贵且容易过拟合。2023-2025 年间,参数高效微调 (PEFT) 技术,特别是低秩适应 (LoRA),成为了解决这一矛盾的关键技术。

4.1 LoRA (Low-Rank Adaptation) 的数学原理与生物学意义

LoRA 的核心思想是基于这样的假设:在适应特定下游任务 (如心肌细胞分割) 时,预训练大模型的权重更新矩阵具有极低的“内在秩” (Intrinsic Rank)。这意味着我们不需要更新所有的权重参数,只需要学习两个极小的低秩矩阵来近似权重的变化¹⁰。

对于 SAM 图像编码器中的每一个 Transformer 层,其权重矩阵 $W_O \in \mathbb{R}^{d \times k}$ 被冻结。LoRA 引入两个可训练的矩阵 $B \in \mathbb{R}^{d \times r}$ 和 $A \in \mathbb{R}^{r \times k}$, 其中 $r \ll \min(d, k)$ 是秩 (Rank)。前向传播过程被修改为:

$$h = W_O x + \Delta W x = W_O x + B A x$$

在心肌细胞分割的语境下，这种分解具有深刻的意义：

- **\$W_0\$ (冻结部分)**: 保留了 SAM 在 SA-1B 数据集上学到的通用边缘检测、纹理识别和空间几何感知能力。这对于识别细胞的基本轮廓至关重要。
- **\$BA\$ (适配部分)**: 专注于学习心肌细胞特有的“语义偏移”(Semantic Shift)。例如，学习识别 α -actinin-2 荧光通道中的周期性条纹是细胞的一部分，而不是背景噪声；或者学习在相差显微镜图像中，晕轮(Halo)效应代表细胞的边界。

4.2 针对心肌细胞的 LoRA 配置策略

根据 SAMed¹⁴ 和 LoRA-MedSAM¹⁰ 的研究经验，针对心肌细胞分割的 LoRA 微调应遵循以下策略：

1. **混合精度注入**: 不应仅在注意力层(Attention Layers, Q/V Projections)注入 LoRA，也应考虑在多层感知机(MLP)层注入。研究表明，MLP 层更多地编码了特定领域的知识，对于生物医学图像的适配效果更好。
2. **秩的选择 (Rank Selection)**: 虽然 $r=4$ 或 $r=8$ 足以处理许多自然图像任务，但对于结构复杂的心肌细胞，建议适当增加秩至 $r=16$ 或 $r=32$ 。这是因为心肌细胞的分割不仅涉及边缘，还涉及对肌节方向场等高频信息的理解，需要更高的模型容量。
3. **Warmup 策略**: 由于冻结了主干，LoRA 模块的初始化极为关键。必须使用带有 Warmup 的学习率调度器(如 Cosine Decay with Warmup)，在前 5%-10% 的训练步数中逐渐增加学习率，以避免训练初期的梯度震荡破坏预训练的特征分布¹⁴。

4.3 Conv-LoRA: 引入归纳偏置以优化边界

2024 年提出的 **Conv-LoRA**¹⁵ 为心肌细胞分割提供了一个极具价值的改进思路。传统的 LoRA 是基于线性层(Linear Layer)的，而 Transformer 架构本身缺乏对局部空间关系的强归纳偏置(Inductive Bias)。

心肌细胞的分割高度依赖于局部边界的连续性。Conv-LoRA 在 LoRA 的并行支路中引入了轻量级的卷积层(Convolutional Layer)。卷积操作具有平移不变性和局部感知能力，能够更有效地捕捉细胞膜的细微曲率变化。公式演变为：

$$h = W_0 x + B A x + \text{Conv}(x)$$

实验表明，Conv-LoRA 在保持参数效率的同时，显著提升了模型对模糊边界的敏感度，减少了分割结果中的锯齿状边缘，这对于精确计算心肌细胞的周长和面积参数至关重要¹⁵。

5. 提示工程的革新：从点提示到骨架提示

SAM 的另一大支柱是提示(Prompt)。对于形态规则的细胞，中心点提示(Point Prompt)或边界框提示(Box Prompt)通常足够。然而，心肌细胞的细长和弯曲形态使得简单的点提示往往只能激活细胞的一部分，导致分割断裂。2023-2025 年的研究引入了更高级的提示策略。

5.1 骨架与中心线提示 (Skeleton/Centerline Prompts)

受血管分割研究的启发¹⁶，骨架提示被证明是处理细长结构的有效手段。

- 原理：首先利用传统的图像处理算法（如 Frangi 滤波）或轻量级粗分割网络提取图像中的管状结构骨架（Skeleton）。然后，沿着骨架进行均匀采样，生成一系列点坐标。
- 应用：将这些沿细胞长轴分布的点集作为正向提示（Positive Prompts）一次性输入 SAM。SAM 的注意力机制会将这些点所覆盖的区域关联起来，强制模型输出一个连通的、覆盖整个长轴的掩码。这有效解决了心肌细胞因中间纹理断裂而被误分为两段的问题。
- SarcGraph 的结合：利用 SarcGraph 检测到的 Z-disc 坐标，可以构建出高精度的“肌节骨架”。将这些 Z-disc 位置作为极高置信度的正向提示，可以确保分割出的区域严格包含肌节结构，排除非心肌细胞¹。

5.2 ScribblePrompt：交互式微调的新范式

ScribblePrompt¹² 提出了一种基于涂鸦（Scribble）的交互式分割范式。与点击不同，涂鸦包含了更多的形状和方向信息。

在微调 CellSAM 时，可以模拟涂鸦交互作为一种数据增强手段。通过算法在 Ground Truth 掩码上生成随机的曲线轨迹（模拟人工涂鸦），并训练 SAM 能够从这些稀疏的线条恢复出完整的细胞形态。对于心肌细胞，一条沿着长轴的简单涂鸦就能提供极强的形状先验，极大地降低了标注难度并提高了分割准确性。研究显示，ScribblePrompt-SAM 在未见过的医学数据集上，仅需极少的交互就能达到全监督模型的性能¹⁹。

6. 综合优化方案：构建高性能心肌细胞分割流水线

基于上述理论分析和技术综述，本报告提出一套针对心肌细胞分割的综合优化方案（Pipeline），旨在整合 CellSAM 的架构优势、LoRA 的训练效率以及 Allen Institute 的领域知识。

6.1 阶段一：数据准备与多模态增强

- 数据源：使用 Allen Institute 的 hiPSC-CM 数据集，包含明场、DAPI（核）和 EGFP- α -actinin-2（肌节）通道。
- 预处理：实施通道融合策略。不要仅使用明场图像，而是将 DAPI 和 Actinin 通道作为额外的输入通道叠加，或通过最大强度投影（MIP）融合。这将使模型能够直接“看到”肌节结构。
- 弱监督信号生成：运行 SarcGraph 算法，生成 Z-disc 的密度图或坐标列表，作为后续训练的辅助监督信号。

6.2 阶段二：模型架构搭建

采用 Cellpose-Guided Conv-LoRA SAM 架构：

1. 提示生成器（Prompt Generator）：训练一个轻量级的 Cellpose 模型（基于 MobileNet 或小规模 ResNet），利用其流场预测能力生成初步的细胞骨架和边界框。这一步不需要极高的精度，只需提供大致的定位和拓扑结构。
2. 主分割器（Main Segmenter）：使用 SAM ViT-Base 作为骨干。

- **PEFT 模块**: 在 Image Encoder 中注入 **Conv-LoRA** (Rank=16), 重点增强对纹理和边界的捕捉能力。
- **Prompt Encoder**: 保持冻结, 接受来自 Cellpose 的骨架点提示 (Skeleton Points) 和边界框提示。
- **Mask Decoder**: 全量微调 (Full Fine-tuning)。由于心肌细胞与自然图像物体的类别差异巨大, Mask Decoder 需要重新学习如何解释图像嵌入。

6.3 阶段三: 混合损失函数训练 (Hybrid Loss Training)

单纯的 IoU Loss 或 Cross-Entropy Loss 不足以约束心肌细胞的形态。建议采用混合损失函数:

$$L_{Total} = \lambda_1 L_{Dice} + \lambda_2 L_{Focal} + \lambda_3 L_{Topo} + \lambda_4 L_{Sarc}$$

- **L_{Dice}** : 关注整体重叠度。
- **L_{Focal}** : 关注难分样本 (如模糊边界)。
- **L_{Topo}** (拓扑损失): 基于骨架的连通性损失, 惩罚断裂的预测结果 (Skeleton Recall Loss)²⁰。
- **L_{Sarc}** (肌节一致性损失): 利用 SarcGraph 的 Z-disc 数据, 惩罚那些包含了非肌节区域或遗漏了肌节区域的分割掩码。

6.4 阶段四: 迭代优化与人机回环 (Human-in-the-Loop)

利用 Cellpose 2.0 提出的“人机回环”理念²¹。

1. 使用微调后的模型对新数据进行预分割。
2. 生物学家使用 GUI (如 Napari 或 Cellpose GUI) 对错误的分割 (如断裂、融合) 进行快速修正。
3. 将修正后的数据通过 LoRA 快速更新模型权重。由于 LoRA 参数量极小, 这种增量学习 (Incremental Learning) 可以在几分钟内完成, 迅速适应不同批次实验的细胞形态差异。

7. 结论与展望

2023-2025 年的研究表明, Segment Anything Model (SAM) 的出现并非终结了特定领域的分割研究, 而是将其推向了更高的维度。针对心肌细胞这一极具挑战性的生物对象, 单纯的“拿来主义”是行不通的。

核心结论:

1. 架构融合是必然: CellSAM 和 Cellpose-SAM 的成功证明, 将 SAM 的通用特征提取能力与特定领域的归纳偏置 (如 Cellpose 的流场、CellFinder 的检测) 相结合, 是解决复杂细胞分割的最优解。
2. **LoRA 使得定制化普及**: LoRA 及其变体 (Conv-LoRA) 打破了基础模型落地的算力壁垒, 使得在单张显卡上训练高性能、定制化的心肌细胞分割模型成为可能。
3. 生物学信息即代码: Allen Institute 的 SarcGraph 工作启示我们, 分割不应仅仅是图像处理,

更应融入生物学先验。将肌节结构信息显式地纳入模型训练(通过提示或损失函数),是实现“生物学感知”分割的关键。

未来展望:
未来的研究将可能集中在 3D 心肌组织分割 和 时序动态分割 上。随着 SAM 2(支持视频分割)的发布 23, 利用时序信息追踪心肌细胞的搏动(Beating)行为, 进而辅助分割静态边界不清的细胞, 将是一个极具潜力的方向。此外, 结合大语言模型(LLM)的多模态代理(Agent)系统 11, 通过自然语言指令(如“分割出所有肌节排列紊乱的细胞”)来驱动 SAM 进行分析, 将彻底改变生物学家的工作方式。

附录: 数据表与性能分析

表 2: 不同微调策略下的资源消耗与性能预估

微调策略	参数更新量 (Params)	显存占用 (Training)	推理速度 (FPS)	预期精度 (Dice)	适用场景
全量微调 (Full FT)	~636M	> 80GB (A100 x2)	< 5	0.88 - 0.90	拥有海量标注数据与算力集群的工业级开发
Freeze Backbone + Decoder FT	~4M	~ 16GB (3090)	~ 10	0.82 - 0.85	算力受限, 但对精度要求不极致的快速实验
LoRA (Rank=8)	~2M	~ 12GB (3080)	~ 10	0.86 - 0.88	推荐: 大部分实验室的最佳性价比选择
Conv-LoRA (Rank=16)	~5M	~ 14GB (3090)	~ 8	0.89 - 0.91	推荐: 针对心肌细胞高精度分割的最佳方案
Adapter (MedSAM)	~20M	~ 24GB (3090/409)	~ 8	0.87 - 0.89	需要较强泛化能力的多

style)		0)			器官任务
--------	--	----	--	--	------

注:数据基于 SAM ViT-Base/Large 架构估算, 实际数值取决于图像分辨率(通常 1024x1024)和具体实现¹⁰。

表 3: Allen Institute 心肌细胞数据集特征与处理建议

数据特征	生物学含义	分割挑战	建议处理方案
各向异性 (Anisotropy)	细胞成熟度标志, 呈长杆状。	易断裂, 长宽比大。	骨架提示 (Skeleton Prompt); Cellpose 流场预测。
肌节纹理 (Striations)	收缩功能单元, 周期性条纹。	易被误认为细胞边缘或多个细胞。	Conv-LoRA 增强局部纹理识别; 多模态输入融合 Actinin 通道。
致密单层 (Monolayer)	细胞间形成紧密连接 (Gap Junctions)。	边界极度模糊, 无间隙。	SarcGraph 辅助验证; 基于流场的后处理分离粘连。
细胞核异质性	可能存在多核 (Binucleation)。	核数目不等于细胞数目。	避免仅使用核作为提示; 结合细胞质/膜染色。

Works cited

1. Quantifying HiPSC-CM structural organization at scale with deep learning-enhanced SarcGraph | PLOS Computational Biology - Research journals, accessed December 27, 2025, <https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1013436>
2. Museum of Spatial Transcriptomics - ResearchGate, accessed December 27, 2025, https://www.researchgate.net/publication/351565056_Museum_of_Spatial_Transcriptomics
3. Quantifying HiPSC-CM Structural Organization at Scale with Deep Learning-Enhanced SarcGraph - arXiv, accessed December 27, 2025, <https://arxiv.org/html/2501.18714v1>
4. Quantifying HiPSC-CM structural organization at scale with deep learning-enhanced SarcGraph | PLOS Computational Biology, accessed

December 27, 2025,

<https://journals.plos.org/ploscompbiol/article/figures?id=10.1371/journal.pcbi.1013436>

5. vanvalenlab/cellSAM: Codebase for "A Foundation Model ... - GitHub, accessed December 27, 2025, <https://github.com/VanValenLab/CellSAM>
6. (PDF) CellSAM: a foundation model for cell segmentation - ResearchGate, accessed December 27, 2025, https://www.researchgate.net/publication/398451184_CellSAM_a_foundation_model_for_cell_segmentation
7. MouseLand/cellpose: a generalist algorithm for cellular ... - GitHub, accessed December 27, 2025, <https://github.com/MouseLand/cellpose>
8. Cellpose-SAM: superhuman generalization for cellular segmentation - bioRxiv, accessed December 27, 2025, <https://www.biorxiv.org/content/10.1101/2025.04.28.651001v1.full-text>
9. Cellpose-SAM: superhuman generalization for cellular segmentation - bioRxiv, accessed December 27, 2025, <https://www.biorxiv.org/content/10.1101/2025.04.28.651001v1>
10. LoRA-MedSAM: efficient medical image segmentation - UQ eSpace, accessed December 27, 2025, <https://espace.library.uq.edu.au/view/UQ:71b2f7f>
11. GenCellAgent: Generalizable, Training-Free Cellular Image Segmentation via Large Language Model Agents - arXiv, accessed December 27, 2025, <https://arxiv.org/html/2510.13896v1>
12. [2312.07381] ScribblePrompt: Fast and Flexible Interactive Segmentation for Any Biomedical Image - arXiv, accessed December 27, 2025, <https://arxiv.org/abs/2312.07381>
13. SAM Fine-Tuning Using LoRA - Labellerr, accessed December 27, 2025, <https://www.labellerr.com/blog/sam-fine-tuning-using-lora/>
14. hitachinsk/SAMed: The implementation of the technical ... - GitHub, accessed December 27, 2025, <https://github.com/hitachinsk/SAMed>
15. [2401.17868] Convolution Meets LoRA: Parameter Efficient Finetuning for Segment Anything Model - arXiv, accessed December 27, 2025, <https://arxiv.org/abs/2401.17868>
16. Accuracy of segment anything model for classification of vascular stenosis in digital subtraction angiography - PMC - NIH, accessed December 27, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12089558/>
17. A Trajectory Point Prompting Segment Anything Model for Zero-Shot Road Extraction From High-Resolution Remote Sensing I - IEEE Xplore, accessed December 27, 2025, <https://ieeexplore.ieee.org/iel8/4609443/10766875/10916599.pdf>
18. VesSAM: Efficient Multi-Prompting for Segmenting Complex Vessel - arXiv, accessed December 27, 2025, <https://arxiv.org/html/2511.00981v1>
19. ScribblePrompt: Fast and Flexible Interactive Segmentation for Any Biomedical Image - European Computer Vision Association, accessed December 27, 2025, https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/05664-suppl.pdf
20. Real-time, Multi-stage Vision-based Dimensional Measurement using Segment

Anything - arXiv, accessed December 27, 2025,
<https://arxiv.org/html/2412.03472v1>

21. cellpose 2.0 tutorial: how to train your own cellular segmentation model - YouTube, accessed December 27, 2025,
<https://www.youtube.com/watch?v=5qANHWoubZU>
22. GUI — cellpose 4.0.7-29-g17fb25f documentation, accessed December 27, 2025,
<https://cellpose.readthedocs.io/en/latest/gui.html>
23. SAM 2: Segment Anything Model 2 - Ultralytics YOLO Docs, accessed December 27, 2025, <https://docs.ultralytics.com/models/sam-2/>