

CellSAM在hiPSC-CM心肌细胞分割任务优化方案的评估

1. 微调策略的合理性

冻结策略与可调参模块：当前方案选择冻结SAM的ViT主干，仅训练Mask Decoder，并结合LoRA/Conv-LoRA进行细粒度调整。这种策略总体符合近期最佳实践。大量研究表明，在有限数据下冻结大型预训练模型的大部分权重，仅调整小型子模块或插入小参数，可有效避免灾难性遗忘并减少过拟合^{1 2}。例如，有工作提出在SAM中**冻结图像编码器和提示编码器，仅对mask解码器进行全量微调**，同时在ViT的自注意力层中注入LoRA适配器³。这种方式利用了SAM已学到的通用视觉特征，避免对全部参数微调导致原有知识丢失¹。因此，冻结ViT主干、训练Mask Decoder的思路是合理的，与Conv-LoRA等方法的做法一致³。

LoRA与Conv-LoRA的应用：引入LoRA（低秩适配）或其卷积改进版Conv-LoRA来调整SAM，有明确的理论与实验证据支持。LoRA通过在Transformer层添加小型可训练矩阵，冻结原模型权重，仅学习低秩更新，大幅降低了训练开销并保留预训练知识^{4 2}。Conv-LoRA进一步在LoRA瓶颈中插入轻量卷积模块，引入局部视觉先验，提升在医学影像等专门领域的表现^{5 6}。这些方法在各种下游分割任务中表现出色，往往只需占用不到1%额外参数却带来显著精度提升^{5 3}。因此，当前方案采用LoRA/Conv-LoRA微调SAM主干是符合潮流的选择。**关于Rank设定与注入层选择：**一般LoRA的秩 r 在4~16为宜，秩过低可能限制模型适应能力，过高则增加过拟合风险⁷。Conv-LoRA论文中以极低参数开销（如总参数增量0.63%）覆盖了ViT各层⁵，说明在每个Transformer层引入适配器能全面注入新领域特征。但也有研究（如NAS-LoRA）提出，不同层对局部先验的需求不同，**可针对性选择注入位置以平衡效果与参数**⁶。在仅有极少数据（3张样本）的情况下，全层注入LoRA可能过拟合，因此可以考虑只在高层注入适配器或降低秩，以确保模型仅学习必要的高层语义调整而非记忆噪声。

提示机制（Prompt）的设计：提示输入对SAM的性能至关重要。目前对比了**DAPI核提示框与骨架提示**两种方案。使用DAPI信号产生的**核位置边界框**作为提示，是一种直接且有效的方法：核染色提供细胞中心位置，用其周围的矩形框提示，可引导SAM分割出包含该核的细胞。这种方法类似近期CellSAM基础模型中的策略——先用检测模型找到细胞位置，再以框作为提示生成掩膜。其优点是简单易实现，已被证明可以在零样本条件下实现对多种细胞的良好分割。相比之下，**骨架提示**（例如基于细胞形态或肌节走向的骨架线）能提供更丰富的形状先验。交互式分割研究表明，相比单点或框，**沿目标延伸的涂鸦/骨架提示提供了更多物体结构信息，可有效帮助分割复杂形状**⁸。对于心肌细胞这种细长不规则形态，骨架提示有望减少断裂、提升连通性。然而，骨架提示在实践中并非SAM原生支持的标准提示类型，需要将骨架表示转换为SAM可用的形式（例如一系列正例点或一幅粗略的mask提示）。如果能够通过算法（如SarcGraph提取细胞主轴）获得细胞骨架，并在训练和推理中将骨架作为提示输入SAM，那么模型可能更准确地**捕捉整个细胞范围，避免将细胞划分成碎片**。总体而言，从当前业界实践看，**使用核框作为提示是稳健且已有成功案例的选择**，而引入骨架提示属于探索前沿，预期有潜在益处但实现复杂度更高，需要验证其增益是否显著。

Loss函数设计：有效的损失函数对微调收敛和性能至关重要。最佳实践是在**分割任务中结合像素级交叉熵/焦损失与基于区域重叠的Dice损失**，以同时兼顾细节和整体轮廓^{9 10}（Dice可缓解前景背景不平衡）。如果当前方案已经采用如**BCE/交叉熵 + Dice损失**的组合，属于常见且有效的设计。此外，在本任务中引入**结构辅助监督**（下文详述的Z-disc密度图和方向图）意味着可能使用多任务损失：主分割损失 + 辅助回归/分类损失。设计上应确保各损失尺度平衡，**不会因辅助任务权重不当干扰主任务优化**。例如，可为 orientation映射预测采用MSE损失，为密度图采用L1或MSE损失，然后通过合理的权重系数将其加和到总损失中。多任务损失的权重通常需要调优；最佳实践是先预训练或暖启动主分割，再逐步增加辅助任务权重，防止模型在小数据下顾此失彼。从文献看，在分割中增加边界

预测、距离变换等辅助任务常能提升主任务精度^{11 9}。因此，本方案的损失设计若涵盖**区域重叠类损失**（如Dice）和**结构一致性损失**，且权重分配合理，就是较为科学的。

综上，从技术视角评估，当前CellSAM微调策略大体符合主流方法：冻结大模型主要部分、参数高效调整、结合恰当提示和复合损失。需注意在超小数据场景下谨慎设定LoRA范围和损失权重，以确保策略的有效性不被过拟合抵消。

2. Allen Institute hiPSC-CM数据处理策略评价

多通道融合利用结构信息： Allen Institute的hiPSC-CM数据包含明场、核染色(DAPI)和 α -肌动蛋白(actinin)等通道¹²。将这些通道融合用于分割是有充分依据的。每个通道提供互补的信息：**明场**呈现细胞的整体形态轮廓和相互边界，**DAPI**标记细胞核定位帮助区分单个细胞， **α -actinin**荧光则揭示细胞内部肌节(Z线)排列。Allen数据集中，活细胞实验甚至额外使用了膜标记以明确细胞边界¹²。在我们没有膜标记的固定细胞图像中，明场+肌动蛋白通道的组合在一定程度上充当了膜标记的角色：明场轮廓和肌节终止的位置共同指示细胞边界。因此，将明场、DAPI、actinin三者融合，理论上**充分利用了细胞结构信息**。这种融合有助于模型同时“看到”**细胞的边界（来自明场）、细胞归属（核定位）和内部纹理（肌节走向）**。例如，如果仅用单一通道，模型可能无法区分紧邻的两细胞（单用actinin时，相邻细胞的肌节纹理可能连成一片；单用明场时内部结构不明显）。多模态融合能利用核位置将细胞分割，利用明场确定形状，用肌节纹理确认细胞范围：这正是Allen原始论文中通过综合多通道获得高质量细胞分割的思路¹²。需要评估的是融合方法：是否简单将三通道堆叠喂给模型？如果SAM的ViT仅接受3通道输入，则直接将它们映射为RGB输入是可行的做法，但需注意通道强度归一化和平衡，避免某通道主导。总体来说，多通道融合策略是合理且必要的，能够**更充分地利用结构信息提高分割准确度**。

3D→2D投影方式： 将3D显微图像投影为2D是处理此数据的关键一步。当前方案采用**逐z层求和的Sum投影**而非Max投影，目的是保留肌节纹理。这个选择在心肌细胞场景下有其合理性：**Sum投影能够累积每一层中的条纹信号，使得较暗但连续的Z线条纹在投影图上得到强化**¹³。相反，Max投影仅取每个像素最大强度，虽然背景更干净，但如果某条肌节纹理在任一单层中不够亮，Max可能完全忽略它，导致细微结构丢失¹³。正如有研究者指出的，Sum投影往往比Max投影**包含更多细节信息但显得模糊、有噪声**，Max投影**图像更锐利而背景干净却可能漏检纤维结构**¹³。在 α -actinin标记的肌节图像中，**肌节条纹属于精细周期结构**，Sum投影可以确保所有层的Z线都对最终强度有贡献，从而保留完整的条纹图案（即所谓肌节纹理）。特别是对于倾斜分布的肌节，可能没有单一切片呈现完整长度的Z线，Sum投影累积信号才能在2D图中显现连续纹理。这对于后续分割模型来说，提供了可利用的周期纹理特征，有助于区分肌细胞内部 vs. 外部区域（细胞外背景没有这种条纹）。当然，Sum投影的缺点是引入模糊和噪声背景，这可能增加分割难度。但如果模型足够健壮（例如通过多通道融合减轻噪声影响），那么**保留纹理细节的收益大于噪声带来的损失**。鉴于我们关注肌节纹理对于识别细胞范围的作用，Sum投影是有益的选择。可考虑在预处理中对Sum投影结果进行适度滤波或归一化，以缓解背景增强的问题。综合来看，在肌肉细胞场景下，**Sum投影优于Max投影**，因为它更完整地保留了sarcomere的条纹细节，符合本任务需求。

SarcGraph辅助监督的恰当性： SarcGraph是一种针对hiPSC-CM影像分析的工具，可自动检测和追踪Z盘和肌节结构^{14 15}。使用SarcGraph生成**Z-disc密度图**和**方向（orientation）图**作为辅助监督，是一项富有创见的策略。其科学合理性表现在：这些衍生图编码了细胞内部结构的高阶信息，有助于引导模型学习到“肌节组织良好的细胞”应具有什么特征。例如，研究显示肌节**方向排列有序、Z盘密集**是成熟心肌细胞的标志¹⁶。Orientation地图使模型了解每个像素所属的肌节方向，可帮助区分属于同一细胞的区域应有一致的纹理取向，不同细胞可能取向中断或差异。Z-disc密度图则反映某区域内Z盘出现的频繁程度或强度，**在细胞内部通常高，在细胞外背景为零**，边界处可能出现密度骤降。作为辅助任务，要求模型去预测这些地图，相当于鼓励其学到肌节的布局 and 连贯性，从而在**分割时避免将肌节连续区域误拆分**。这种多任务学习思想与其他领域相通：例如道路提取中联合学习道路方向可以提

高连通性¹⁷；医学分割中加入边界或形状描述任务能提升主任务表现¹¹⁹。因此，理论上利用SarcGraph输出指导模型，是合理且可能有效的。

当然，实施中需注意：**SarcGraph本身检测可能存在误差¹⁸**，应确保提供给模型的密度/方向图质量可靠，否则模型可能学习到错误模式。不过Allen最新研究对SarcGraph算法做了改进，提高了低成熟度细胞中Z盘检测的可靠性¹⁸。在我们的应用中，这些辅助监督主要用于**提供细胞结构的先验**，而非直接决定边界。如果权重平衡适当，它们会让模型更“理解”何处应属同一细胞（例如同一条肌节走向连贯的区域应连为一体）。综言之，**使用SarcGraph生成的Z盘密度图和方向图作为辅助监督是恰当的**。这一策略将领域知识（肌节结构规律）显式融入网络训练，有望提高分割结果对细胞生物学一致性的符合程度。这在心肌细胞这样的高度结构化对象分割中，是很有价值的创新。

3. 下一阶段的优化建议

基于目前的工程实现（已有3个样本数据、训练脚本，配套的Napari可视化GUI，以及已开通的ALICE HPC算力），为了进一步提高CellSAM在心肌细胞分割任务中的表现，提出以下优化建议：

- 1. 引入骨架/多点提示以减少断裂误差（优先级：高）**：建议尝试将“骨架提示”融入模型交互。在训练阶段，可模拟给定细胞内部多点提示（例如沿细胞纵轴每隔一定距离采样正例点），让SAM学会在有多多个内部点提示时输出单个连通的细胞掩膜。⁸ 研究指出，涂鸦式多点提示提供了比单点/框更多的形状信息，能有效减少复杂目标分割的漏段。因此，在推理时结合DAPI核框和额外内部点（来自细胞骨架算法或人工交互）一起作为提示，模型有望更准确地连通整个细胞区域，显著降低将同一细胞分成碎片的错误。¹⁷的工作也表明，通过**联合学习方向信息**，分割模型能增强连通性；这支持了我们的思路——骨架提示本质上给予了方向和延展信息，预计能提升心肌细胞分割的完整性。实现上，可利用Napari界面的便利，让用户在每个细胞内快速划几笔（或点击几点）作为提示，提高半自动分割质量。
- 2. 监控过拟合并扩充训练数据（优先级：高）**：当前仅有3个训练样本，极易发生过拟合风险。这会导致模型在训练数据上效果很好，但推广到新图像时精度骤降。强烈建议：**(a)** 使用数据增广技术扩充样本多样性，例如随机旋转、翻转、亮度变化，以及模拟不同成熟度的肌节纹理（可通过频域扰动actinin通道来实现）；**(b)** 采取交叉验证评估，即使数据很少也尽量做留一验证，监控训练和验证损失差异，及时采用提前停止 (Early Stopping)策略；**(c)** 如果可能，获取并加入更多标注数据。Allen公开数据集实际上包含上万细胞的手动/自动分割结果¹²，可以考虑抽取一部分作为额外训练监督，从而弥补自有标注的不足。由于HPC资源已就绪，利用更多数据进行训练在算力上是可行的。确保模型不因过拟合而记忆了训练集特定背景或噪声，对于最终实用性至关重要。¹的研究也强调，**小样本下全模型微调会损害泛化能力**，因此我们应持续坚持参数高效微调策略，并通过上述手段降低过拟合风险。
- 3. 优化LoRA配置与模型规模以缓解资源瓶颈（优先级：中）**：虽然已有HPC支持，但仍需关注显存和计算开销。SAM的ViT模型很大，微调时若LoRA插入过多层、秩太高，可能超出显存或导致训练缓慢。建议：**(a) 根据数据规模调整LoRA秩**，初步实验可选择较小秩（如4或8）以减少参数，待有更多数据时再提高秩提升容量；**(b) 选择性加载较小的SAM变体**（如ViT-B权重）进行微调，如果精度可以接受，将大幅降低资源占用；**(c)** 利用分布式训练或混合精度训练(FP16/BF16)充分利用HPC算力。在验证模型性能之前，不宜贸然增加模型复杂度，以免浪费资源却收效甚微。先确保基础方案在当前资源下顺利跑通并得到改进，再考虑更大规模的实验。
- 4. 逐步迭代实验以快速产出结果（优先级：中）**：为了尽快看到有意义的结果，推荐采用**循序渐进的轻量实验路径**而非一上来实现所有想法。具体步骤：首先，在现有3张样本上**训练基础模型**（冻结ViT+微调Decoder，使用核框提示，基础损失），获得一个基线分割性能。接着，**逐项引入改进**：如先加入Dice损失

观察提升，然后加入LoRA观察提升，再引入辅助任务（orientation/密度）观察效果。每一步变化都在验证集（或留一法）上评估，与前一版本比较。这种迭代能够快速定位哪些改进最有价值。由于需求可能偏向尽快出成果，建议优先尝试**见效快的改进**：例如**骨架/多点提示**属于改动较小但可能显著改善用户直观感受的措施，可尽早融入工作流（哪怕暂时不融入训练，也可以在推理时人工提供骨架提示来提高分割）。再比如，可以调用**预训练的CellSAM基础模型**进行零样本推理，将结果通过Napari人工校正后作为额外训练数据（主动学习思路）。这些“小步快跑”的策略能在短时间内产出有用结果，同时为后续大型严谨实验奠定基础。

5. 改进方案优先级与预期效果总结：为方便决策，综合以上建议：

6. **高优先级**：增加骨架/多点提示（预期大幅降低单细胞碎片漏分，提高分割完整性），扩充数据防过拟合（预期显著提升模型泛化能力）。
7. **中优先级**：优化LoRA注入范围与模型大小（预期在保持性能前提下降低资源压力，训练更稳健），采用渐进实验策略快速验证想法（预期及时发现有效改进，缩短研发周期）。
8. **较低优先级**：如有富余时间和数据，再考虑更复杂的改进例如结合**多模态提示**（例如将转录信号或其它模态信息融入提示，提高困难情况下的分割准确率）等。这类改进目前缺乏直接证据，且实现成本高，在主要问题解决前可暂缓。

总之，下一阶段应着眼于**增强模型对心肌细胞特殊结构的理解**（通过骨架提示和结构辅助任务）和**保障小数据条件下的稳健训练**。先采用轻量可行的方案取得阶段性成果，再逐步拓展到更加全面和精细的优化。这样既能满足快速出成果的要求，又为后续性能极限提升打下基础。每项建议均基于当前文献和实践推断，预期能对心肌细胞分割的准确性和可靠性产生积极影响。 17 19

1 2 19 An efficient fine tuning strategy of segment anything model for polyp segmentation | Scientific Reports

[https://www.nature.com/articles/s41598-025-97802-w?](https://www.nature.com/articles/s41598-025-97802-w?error=cookies_not_supported&code=74fe69fb-8d1f-4e8e-95bb-441fa44b84ec)

[error=cookies_not_supported&code=74fe69fb-8d1f-4e8e-95bb-441fa44b84ec](https://www.nature.com/articles/s41598-025-97802-w?error=cookies_not_supported&code=74fe69fb-8d1f-4e8e-95bb-441fa44b84ec)

3 6 NAS-LoRA: Empowering Parameter-Efficient Fine-Tuning for Visual Foundation Models with Searchable Adaptation

<https://arxiv.org/html/2512.03499v1>

4 7 SAM Fine-Tuning Using LoRA

<https://www.labellerr.com/blog/sam-fine-tuning-using-lora/>

5 [Quick Review] Convolution Meets LoRA: Parameter Efficient Finetuning for Segment Anything Model

<https://liner.com/review/convolution-meets-lora-parameter-efficient-finetuning-for-segment-anything-model>

8 ScribblePrompt: Fast and Flexible Interactive Segmentation for Any Medical Image

<https://arxiv.org/html/2312.07381v1>

9 Boosting Semantic Segmentation with Semantic Boundaries

https://www.researchgate.net/publication/370127389_Boosting_Semantic_Segmentation_with_Semantic_Boundaries

10 Local Shape Descriptors for Neuron Segmentation

<https://localshapedescriptors.github.io/>

11 BoundarySeg : An Embarrassingly Simple Method To Boost Medical ...

<https://arxiv.org/html/2505.09829v1>

12 15 16 18 Quantifying HiPSC-CM Structural Organization at Scale with Deep Learning-Enhanced SarcGraph

<https://arxiv.org/html/2501.18714v1>

13 Confocal image deconvolution: stack projection by sum slices or by maximum intensity? | ResearchGate

https://www.researchgate.net/post/Confocal_image_deconvolution_stack_projection_by_sum_slices_or_by_maximum_intensity

14 [2102.02412] Sarc-Graph: Automated segmentation, tracking, and analysis of sarcomeres in hiPSC-derived cardiomyocytes

<https://arxiv.org/abs/2102.02412>

17 Improved Road Connectivity by Joint Learning of Orientation and Segmentation

https://openaccess.thecvf.com/content_CVPR_2019/papers/

Batra_Improved_Road_Connectivity_by_Joint_Learning_of_Orientation_and_Segmentation_CVPR_2019_paper.pdf